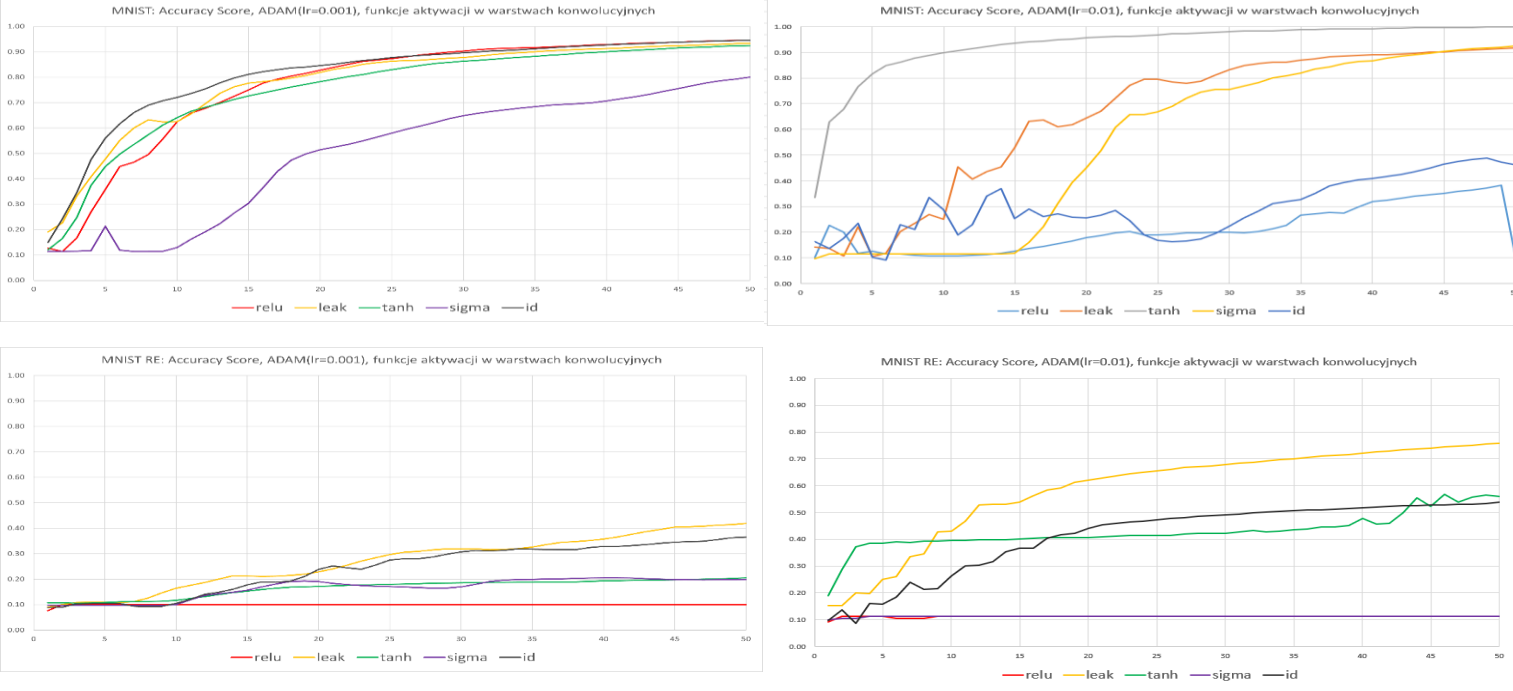




2.1 Opis dwóch architektur sieci splotowej dla zbioru MNIST – badanie wpływu funkcji aktywacji



MNIST – funkcja aktywacji tanh, lr=0.01		MNIST zredukowany – funkcja aktywacji leaky ReLU, lr=0.01	
Confusion Matrix	Accuracy Score	Confusion Matrix	Accuracy Score
	1,0		0,80

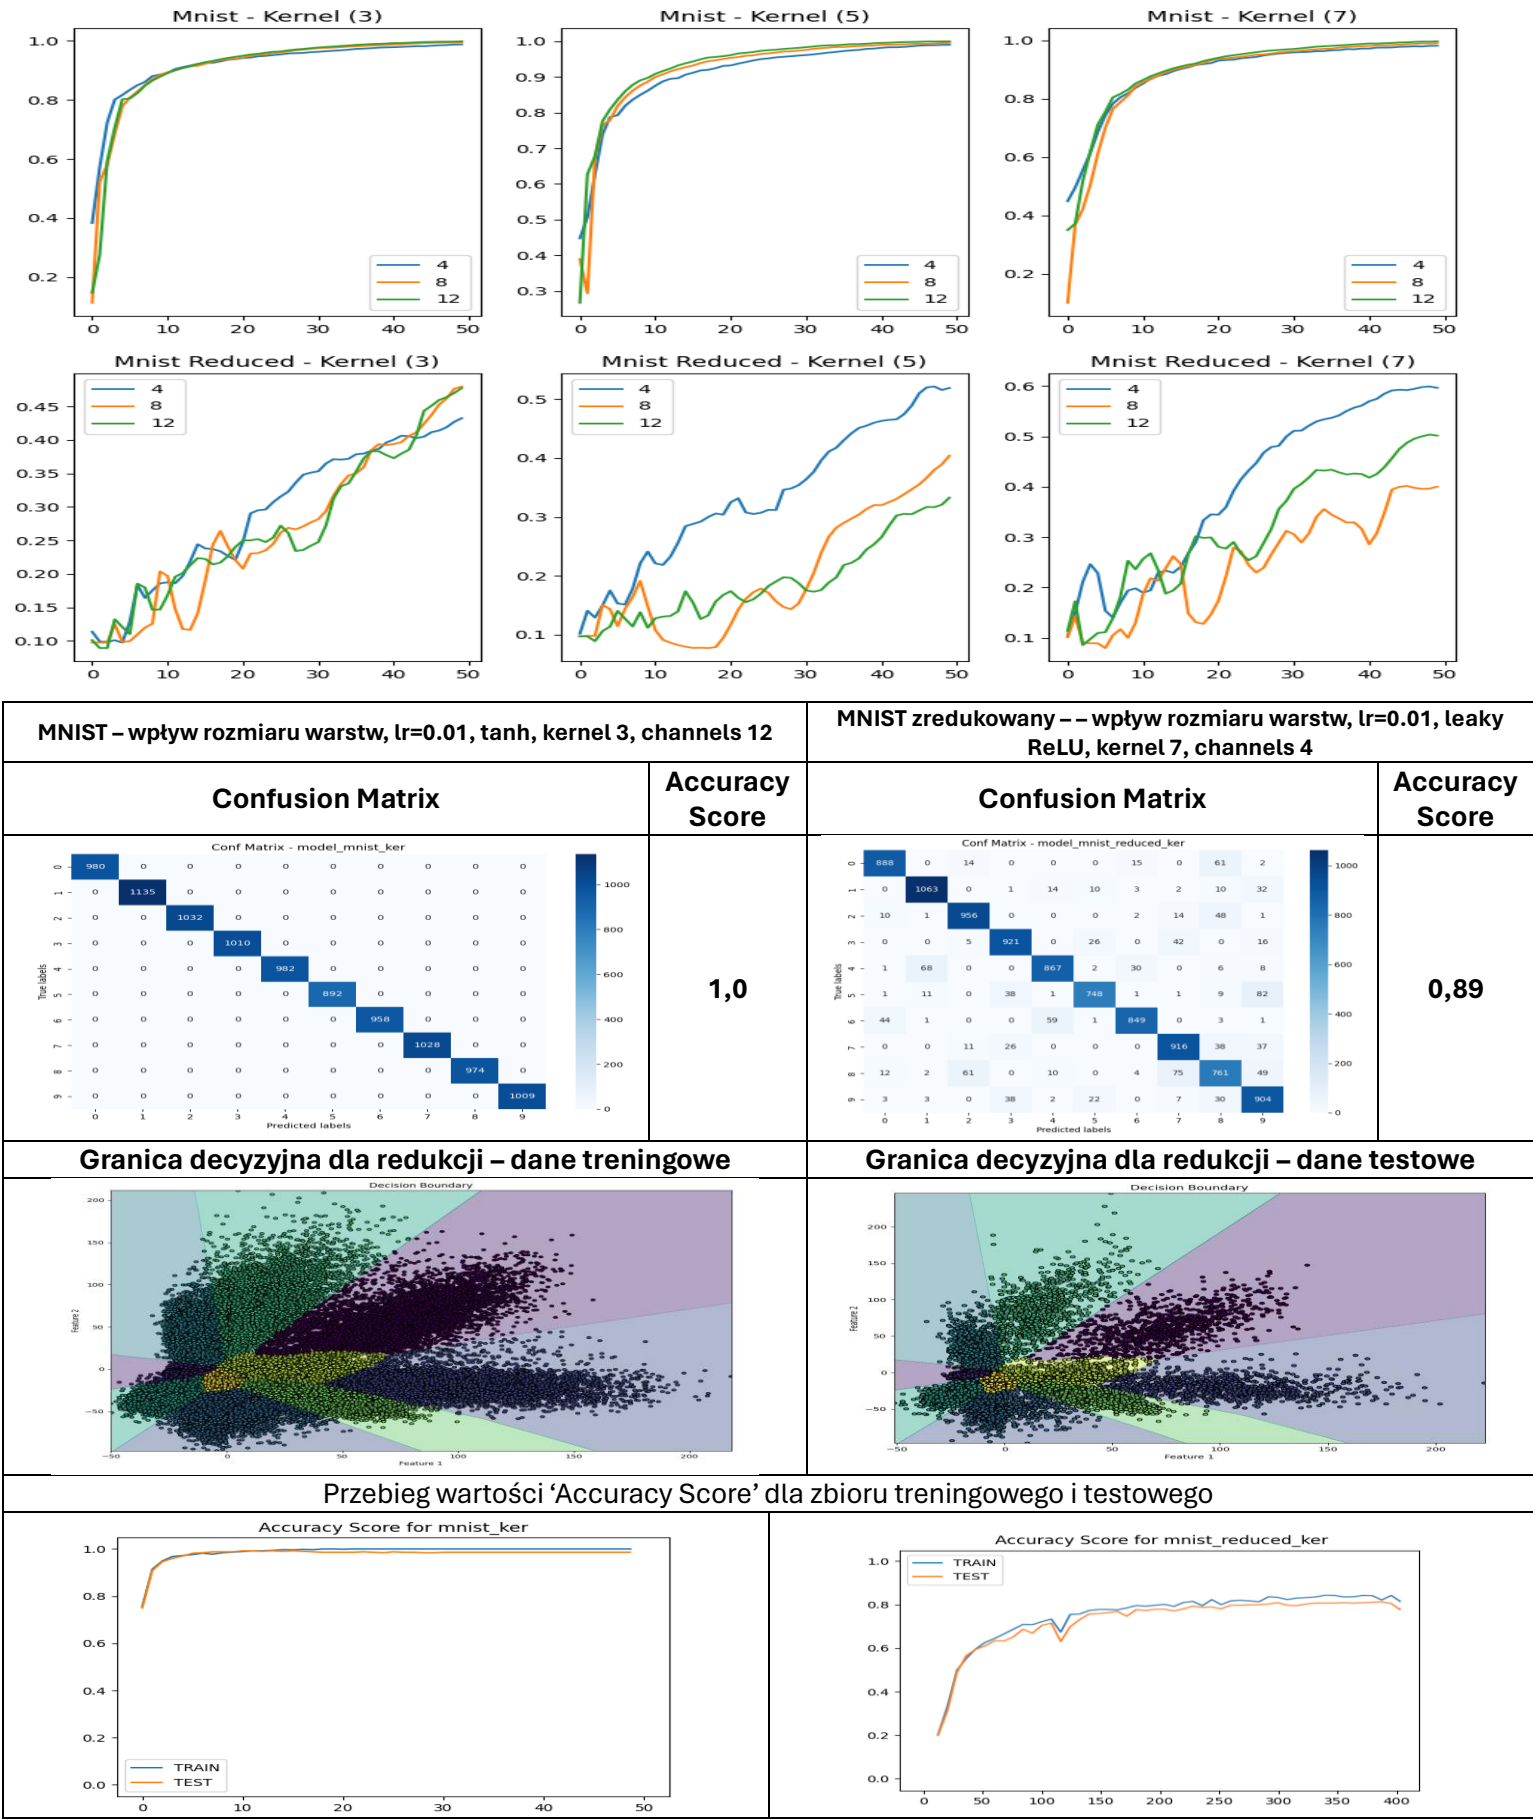


Przebieg wartości ‘Accuracy Score’ dla zbioru treningowego i testowego



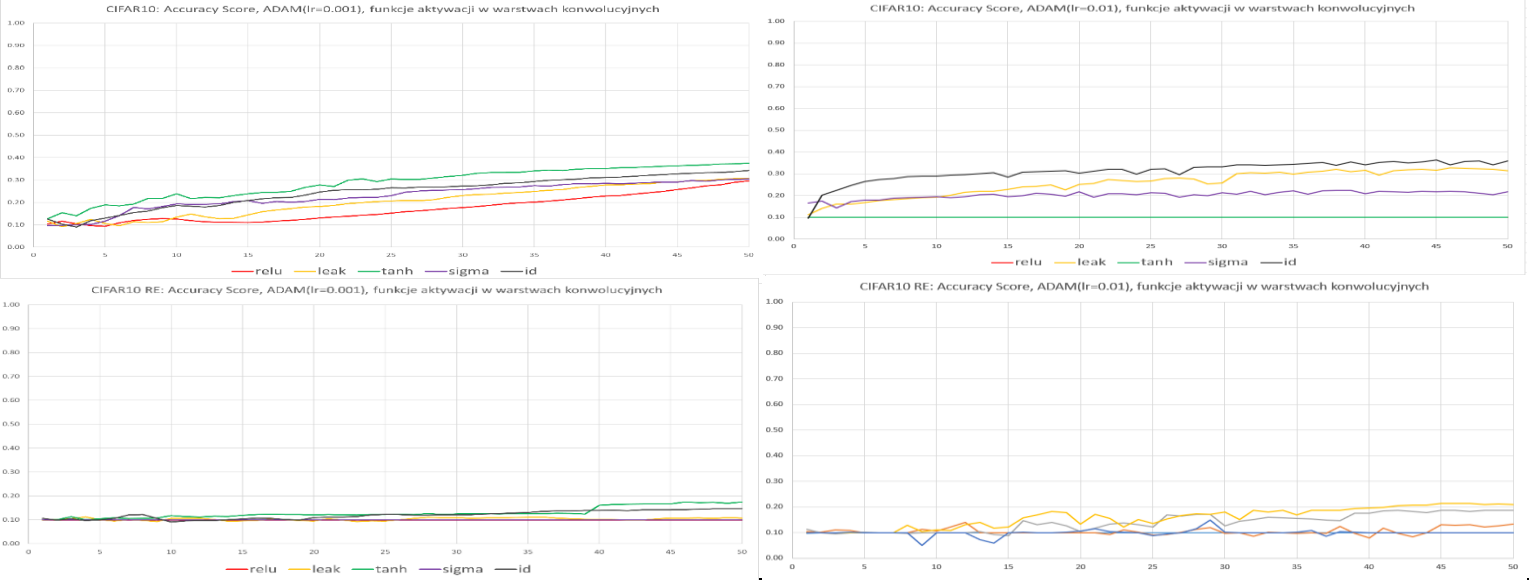
Model bazowy składał się z części ekstrakcyjnej (warstwy konwolucyjnej o jądrze 5 rzutującej na 8 kanałów, wybranej funkcji aktywacji, pooling metodą maksymalnej wartości macierzą 2x2, kolejnej warstwy konwolucyjnej rzutującej na 16 kanałów i ponownie funkcji aktywacji i pooling) oraz części liniowej (warstwa liniowa z funkcją aktywacji RELU oraz kolejna warstwa liniowa prowadząca do wektora etykiet). W przypadku ekstrakcji do dwóch cech druga warstwa konwolucyjna miała jądro o wymiarach otrzymanych obrazów i rzutowała na dwa kanały, by otrzymać w ten sposób dwie cechy na które wpływa cały obraz. Dla różnych wartości Learning Rate optymalizatora ADAM przetestowano 5 różnych funkcji aktywacji dla warstw konwolucyjnych i wybrano model z najszybszym przyrostem wskaźnika Accuracy Score, odpowiednio TANH i Leaky RELU z nachyleniem wstecznym 0.33 dla zbioru zredukowanego, przy learning rate 0.01. Rozmiary warstw liniowych dobrano na podstawie wyników w części pierwszej projektu.

2.2 Opis dwóch architektur sieci splotowej dla zbioru MNIST – badanie wpływu rozmiaru warstw


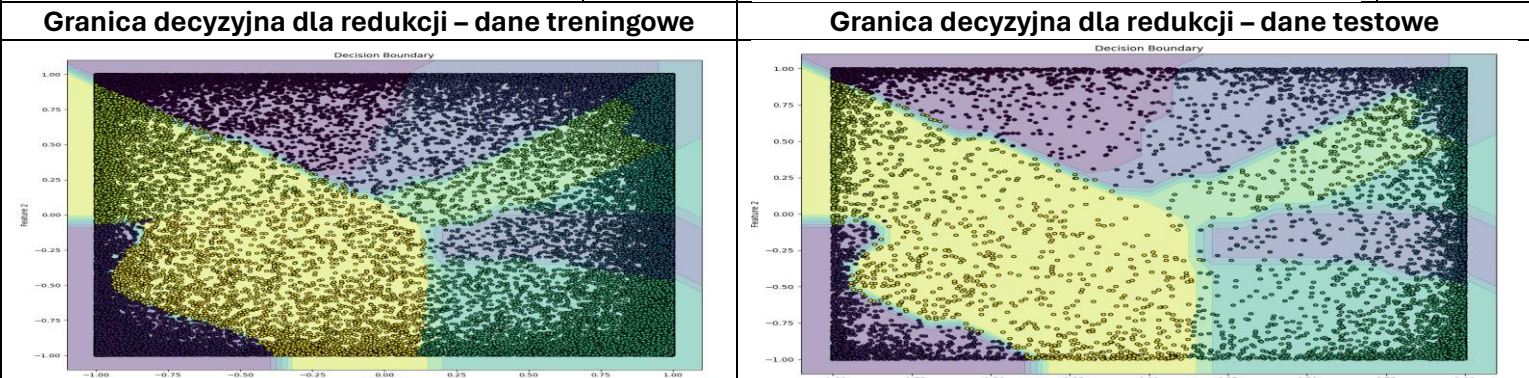


Korzystając z wyników otrzymanych w poprzednim eksperymencie, ponownie przetestowano modele zmieniając rozmiary jądra pierwszej warstwy konwolucyjnej oraz ilość jej wyjściowych kanałów i zbadano ich wpływ na jakość klasyfikacji. Jako najlepszy model wybrano ten o najszybszym przyroście wskaźnika Accuracy Score. Wybrano odpowiednio rozmiar jądra równy 3 i 12 kanałów oraz rozmiar jądra 7 i 4 kanały dla zbioru zredukowanego.

2.3 Opis dwóch architektur sieci splotowej dla zbioru CIFAR10 – badanie wpływu funkcji aktywacji

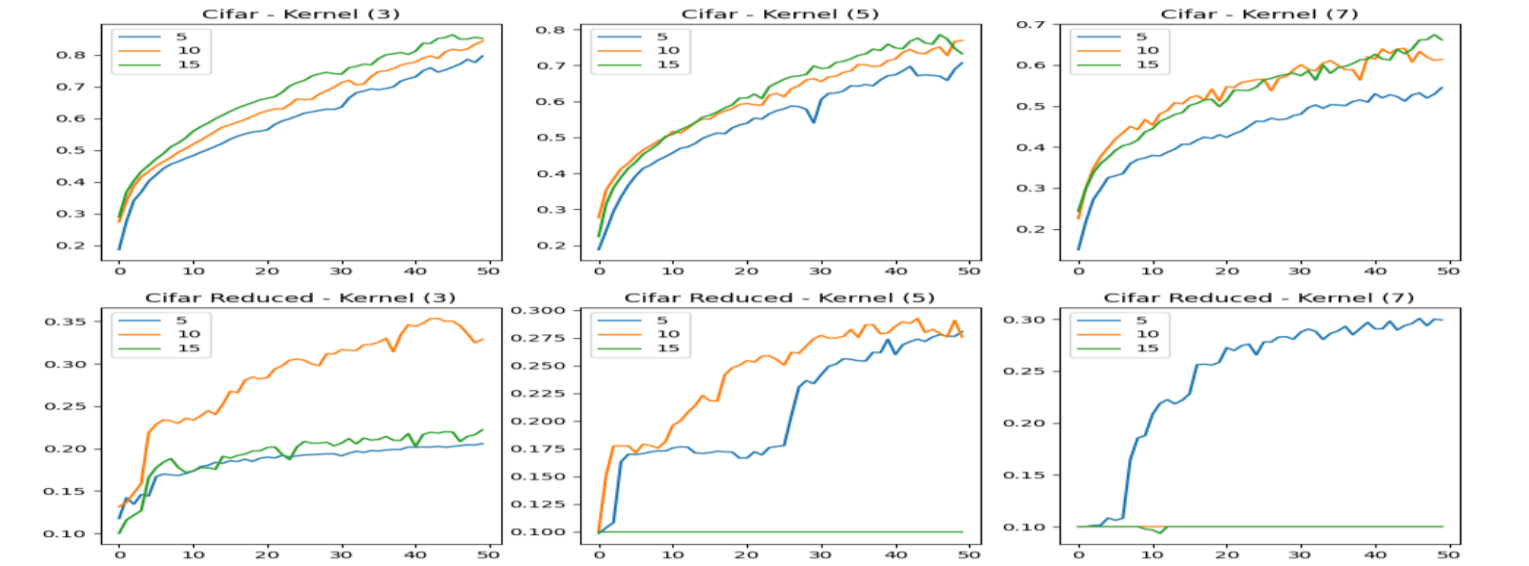


CIFAR10 – funkcja aktywacji tanh, lr=0.001										CIFAR10 zredukowany – funkcja aktywacji tanh, lr=0.001																																																																																																																																																																																																																																																													
Confusion Matrix										Accuracy Score	Confusion Matrix										Accuracy Score																																																																																																																																																																																																																																																		
<div>Conf Matrix - model_cifar_activ</div> <table><tr><td>0</td><td>818</td><td>29</td><td>38</td><td>4</td><td>14</td><td>1</td><td>7</td><td>8</td><td>68</td><td>13</td></tr><tr><td>1</td><td>17</td><td>841</td><td>6</td><td>7</td><td>4</td><td>3</td><td>8</td><td>3</td><td>34</td><td>77</td></tr><tr><td>2</td><td>60</td><td>15</td><td>693</td><td>52</td><td>58</td><td>55</td><td>20</td><td>21</td><td>18</td><td>8</td></tr><tr><td>3</td><td>19</td><td>16</td><td>52</td><td>648</td><td>32</td><td>131</td><td>45</td><td>18</td><td>15</td><td>24</td></tr><tr><td>4</td><td>34</td><td>11</td><td>65</td><td>39</td><td>706</td><td>34</td><td>37</td><td>45</td><td>17</td><td>12</td></tr><tr><td>5</td><td>7</td><td>9</td><td>40</td><td>115</td><td>24</td><td>731</td><td>31</td><td>26</td><td>10</td><td>7</td></tr><tr><td>6</td><td>9</td><td>8</td><td>33</td><td>63</td><td>28</td><td>42</td><td>791</td><td>10</td><td>5</td><td>11</td></tr><tr><td>7</td><td>8</td><td>7</td><td>14</td><td>25</td><td>37</td><td>15</td><td>8</td><td>867</td><td>8</td><td>11</td></tr><tr><td>8</td><td>65</td><td>32</td><td>14</td><td>9</td><td>9</td><td>4</td><td>4</td><td>5</td><td>837</td><td>21</td></tr><tr><td>9</td><td>15</td><td>83</td><td>4</td><td>18</td><td>6</td><td>8</td><td>12</td><td>10</td><td>34</td><td>810</td></tr><tr><td></td><td>0</td><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td></tr></table>										0	818	29	38	4	14	1	7	8	68	13	1	17	841	6	7	4	3	8	3	34	77	2	60	15	693	52	58	55	20	21	18	8	3	19	16	52	648	32	131	45	18	15	24	4	34	11	65	39	706	34	37	45	17	12	5	7	9	40	115	24	731	31	26	10	7	6	9	8	33	63	28	42	791	10	5	11	7	8	7	14	25	37	15	8	867	8	11	8	65	32	14	9	9	4	4	5	837	21	9	15	83	4	18	6	8	12	10	34	810		0	1	2	3	4	5	6	7	8	9	0,77	<div>Conf Matrix - model_cifar_reduced_activ</div> <table><tr><td>0</td><td>577</td><td>18</td><td>71</td><td>9</td><td>44</td><td>10</td><td>21</td><td>13</td><td>225</td><td>12</td></tr><tr><td>1</td><td>20</td><td>615</td><td>3</td><td>7</td><td>2</td><td>1</td><td>44</td><td>1</td><td>50</td><td>257</td></tr><tr><td>2</td><td>65</td><td>4</td><td>188</td><td>41</td><td>454</td><td>85</td><td>74</td><td>59</td><td>25</td><td>5</td></tr><tr><td>3</td><td>10</td><td>6</td><td>72</td><td>195</td><td>172</td><td>130</td><td>361</td><td>37</td><td>7</td><td>10</td></tr><tr><td>4</td><td>38</td><td>4</td><td>123</td><td>60</td><td>525</td><td>109</td><td>79</td><td>47</td><td>12</td><td>3</td></tr><tr><td>5</td><td>9</td><td>1</td><td>88</td><td>152</td><td>328</td><td>164</td><td>213</td><td>37</td><td>5</td><td>3</td></tr><tr><td>6</td><td>3</td><td>7</td><td>19</td><td>113</td><td>74</td><td>36</td><td>719</td><td>11</td><td>3</td><td>15</td></tr><tr><td>7</td><td>14</td><td>2</td><td>175</td><td>66</td><td>462</td><td>101</td><td>81</td><td>82</td><td>9</td><td>8</td></tr><tr><td>8</td><td>411</td><td>64</td><td>34</td><td>7</td><td>11</td><td>5</td><td>17</td><td>3</td><td>406</td><td>42</td></tr><tr><td>9</td><td>33</td><td>537</td><td>11</td><td>8</td><td>3</td><td>1</td><td>66</td><td>5</td><td>31</td><td>305</td></tr><tr><td></td><td>0</td><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td></tr></table>										0	577	18	71	9	44	10	21	13	225	12	1	20	615	3	7	2	1	44	1	50	257	2	65	4	188	41	454	85	74	59	25	5	3	10	6	72	195	172	130	361	37	7	10	4	38	4	123	60	525	109	79	47	12	3	5	9	1	88	152	328	164	213	37	5	3	6	3	7	19	113	74	36	719	11	3	15	7	14	2	175	66	462	101	81	82	9	8	8	411	64	34	7	11	5	17	3	406	42	9	33	537	11	8	3	1	66	5	31	305		0	1	2	3	4	5	6	7	8	9	0,38
0	818	29	38	4	14	1	7	8	68	13																																																																																																																																																																																																																																																													
1	17	841	6	7	4	3	8	3	34	77																																																																																																																																																																																																																																																													
2	60	15	693	52	58	55	20	21	18	8																																																																																																																																																																																																																																																													
3	19	16	52	648	32	131	45	18	15	24																																																																																																																																																																																																																																																													
4	34	11	65	39	706	34	37	45	17	12																																																																																																																																																																																																																																																													
5	7	9	40	115	24	731	31	26	10	7																																																																																																																																																																																																																																																													
6	9	8	33	63	28	42	791	10	5	11																																																																																																																																																																																																																																																													
7	8	7	14	25	37	15	8	867	8	11																																																																																																																																																																																																																																																													
8	65	32	14	9	9	4	4	5	837	21																																																																																																																																																																																																																																																													
9	15	83	4	18	6	8	12	10	34	810																																																																																																																																																																																																																																																													
	0	1	2	3	4	5	6	7	8	9																																																																																																																																																																																																																																																													
0	577	18	71	9	44	10	21	13	225	12																																																																																																																																																																																																																																																													
1	20	615	3	7	2	1	44	1	50	257																																																																																																																																																																																																																																																													
2	65	4	188	41	454	85	74	59	25	5																																																																																																																																																																																																																																																													
3	10	6	72	195	172	130	361	37	7	10																																																																																																																																																																																																																																																													
4	38	4	123	60	525	109	79	47	12	3																																																																																																																																																																																																																																																													
5	9	1	88	152	328	164	213	37	5	3																																																																																																																																																																																																																																																													
6	3	7	19	113	74	36	719	11	3	15																																																																																																																																																																																																																																																													
7	14	2	175	66	462	101	81	82	9	8																																																																																																																																																																																																																																																													
8	411	64	34	7	11	5	17	3	406	42																																																																																																																																																																																																																																																													
9	33	537	11	8	3	1	66	5	31	305																																																																																																																																																																																																																																																													
	0	1	2	3	4	5	6	7	8	9																																																																																																																																																																																																																																																													



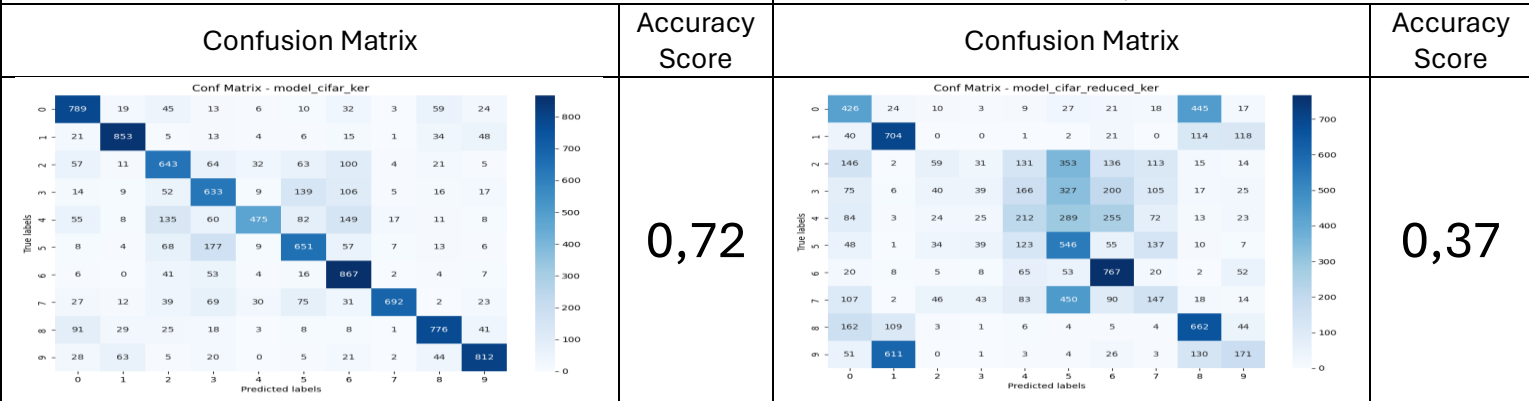
Model bazowy składał się z części ekstrakcyjnej (warstwy konwolucyjnej o jądrze 7 rzutującej na 10 kanałów, wybranej funkcji aktywacji, poolingu metodą maksymalnej wartości macierzą 2x2, kolejnej warstwy konwolucyjnej rzutującej na 20 kanałów i ponownie funkcji aktywacji i poolingu) oraz części liniowej (warstwa liniowa z funkcją aktywacji RELU oraz kolejna warstwa liniowa prowadząca do wektora etykiet). W przypadku ekstrakcji do dwóch cech druga warstwa konwolucyjna miała jądro o wymiarach otrzymanych obrazów i rzutowała na dwa kanały, by otrzymać w ten sposób dwie cechy na które wpływa cały obraz. Dla różnych wartości Learning Rate optymalizatora ADAM przetestowano 5 różnych funkcji aktywacji dla warstw konwolucyjnych i wybrano model z najszybszym przyrostem wskaźnika Accuracy Score, w obu przypadkach zastosowano aktywację TANH oraz learning rate 0.001 ze względu na lepsze wyniki przy dłuższym uczeniu. Rozmiary warstw liniowych dobrano na podstawie wyników w części pierwszej projektu.

2.4 Opis dwóch architektur sieci splotowej dla zbioru CIFAR – badanie wpływu rozmiaru warstw



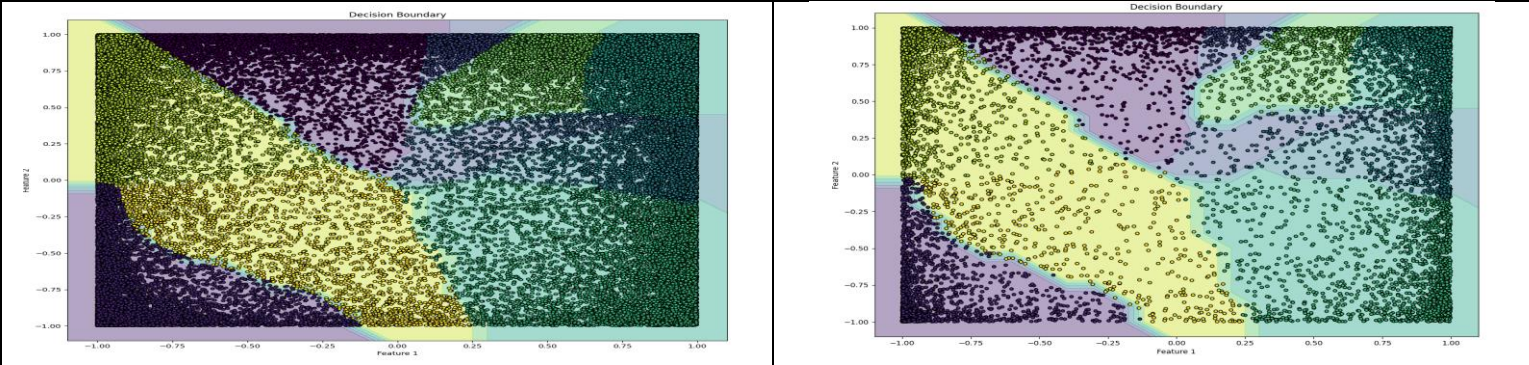
CIFAR10 – wpływ rozmiaru warstw, tanh, lr=0.001, kernel 3, channels 15

CIFAR10 zredukowany – wpływ rozmiaru warstw, tanh, lr=0.001, kernel 3, channels 10

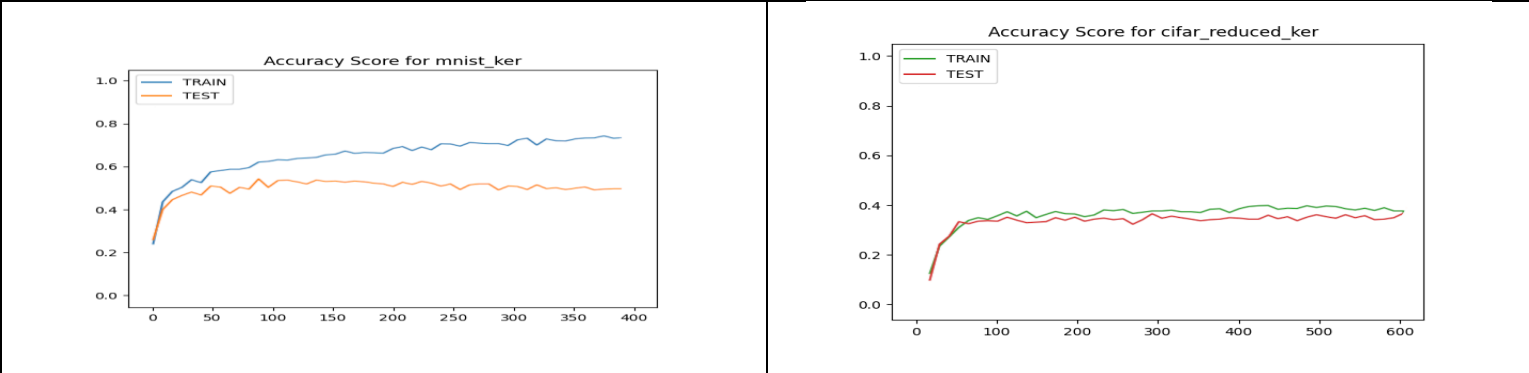


Granica decyzyjna dla redukcji – dane treningowe

Granica decyzyjna dla redukcji – dane testowe



Przebieg wartości 'Accuracy Score' dla zbioru treningowego i testowego



Korzystając z wyników otrzymanych w poprzednim eksperymencie, ponownie przetestowano modele zmieniając rozmiary jądra pierwszej warstwy konwolucyjnej oraz ilość jej wyjściowych kanałów i zbadano ich wpływ na jakość klasyfikacji. Jako najlepszy model wybrano ten o najszybszym przyroście wskaźnika Accuracy Score. Wybrano odpowiednio rozmiar jądra równy 3 i 15 kanałów oraz rozmiar jądra 3 i 10 kanałów dla zbioru zredukowanego.

2.5 Wyniki eksperymentu drugiego dla najlepszych architektur dla zbioru MNIST


Średnia wartość 'Accuracy Score' z 10 treningów oraz 'Odchylenie standardowe' dla 10 treningów na zbiorze MNIST.

augmentacja	Średnia - MNIST				Odchylenie standardowe - MNIST			
	all	100	200	1000	all	100	200	1000
bez	0.99	0.76	0.86	0.95	0.00072	0.0084	0.0155	0.0024
rotacja	0.99	0.80	0.85	0.95	0.00079	0.0088	0.0220	0.0017
kontrast itd.	0.99	0.78	0.86	0.95	0.00070	0.0323	0.0191	0.0025


augmentacja	Średnia - MNIST reduced				Odchylenie standardowe - MNIST reduced			
	all	100	200	1000	all	100	200	1000
bez	0.82	0.40	0.39	0.64	0.0063	0.066	0.13	0.021
rotacja	0.82	0.33	0.32	0.66	0.0058	0.113	0.18	0.027
kontrast itd.	0.82	0.35	0.36	0.66	0.0077	0.085	0.12	0.022

Rozkład danych treningowych dla 100 przykładów oraz przypadek, gdy dla każdego ze 100 przykładów zastosowana została augmentacja – zmiana wartości saturacji, kontrastu itd.



100 przykładów



100 przykładów z zastosowaną 10 razy augmentacją rotacji o kąt w przedziale <0,20>



Przykładowe obrazy przed i po augmentacji



Augmentacje dla zbioru MNIST to: rotacja o kąt w przedziale <0,15> stopni oraz zmiana saturacji, kontrastu i jasności zapisanej liczby – wybrane zostały za najbardziej sensowne, ponieważ liczba może zostać zapisana pod pewnym kątem, nie zawsze idealnie prosto oraz mogą również zostać zapisane grubszym pociągnięciem, co zmiana jasności piksela pozwoli nam wychwycić.

2.6 Wyniki eksperymentu drugiego dla najlepszych architektur dla zbioru CIFAR10


Średnia wartość 'Accuracy Score' z 10 treningów oraz 'Odchylenie standardowe' dla 10 treningów na zbiorze CIFAR10.

augmentacja	Średnia - CIFAR10 reduced				Odchylenie standardowe - CIFAR10 reduced			
	all	100	200	1000	all	100	200	1000
bez	0.31	0.13	0.10	0.25	0.00035	0.030	1.0E-04	0.0026
rotacja	0.31	0.12	0.10	0.24	0.00505	0.022	0.0012	0.0088
kontrast itd.	0.31	0.15	0.10	0.20	0.00175	0.037	0	0.035


augmentacja	Średnia - CIFAR10				Odchylenie standardowe - CIFAR10			
	all	100	200	1000	all	100	200	1000
bez	0.55	0.21	0.23	0.38	0.008	0.007	0.049	0.0059
rotacja	0.54	0.23	0.21	0.36	0.007	0.008	0.043	0.0086
kontrast itd.	0.55	0.22	0.21	0.37	0.005	0.010	0.058	0.0070

Rozkład danych treningowych dla 100 przykładów oraz przypadek, gdy dla każdego ze 100 przykładów zastosowana została augmentacja – zmiana wartości saturacji, kontrastu itd.


100 przykładów



100 przykładów z zastosowaną 10 razy augmentacją rotacji o kąt w przedziale <0,20>



Przykładowe obrazy przed i po augmentacji



Augmentacje dla zbioru CIFAR10 to również: rotacja o kąt w przedziale <0,10> stopni oraz zmiana saturacji, kontrastu i jasności zapisanego obrazka – wybrane zostały za najbardziej sensowne, ponieważ zrobione zdjęcie obiektu czy zwierzęcia może być czasami niedokładne, może mieć źle odwzorowane kolory czy może być zrobione pod kątem przez niepoprawnie trzymany obiektyw. Dodatkowo, zmiana kolorów zwierząt na losowe wydaje się kontrproduktywna.

2.7 Analiza i wnioski

Wyniki z eksperymentu pierwszego sugerują, że parametr Learning Rate optymalizatora ADAM jest ściśle związany ze skomplikowaniem zbioru. Zbiory MNIST, które są dobrze odseparowane i mają relatywnie niewiele zmiennych pracują lepiej na wyższych wartościach tego parametru, podczas gdy zbiór CIFAR10 miał znaczny problem przy jego wyższych wartościach. Przy zbyt dużym zwiększeniu optymalizator wykazywał niestabilne zachowanie, natomiast przy zbyt małym postęp w uczeniu był niezauważalny. Odpowiedni dobór parametru Learning Rate może znacząco wpłynąć na efektywność naszego modelu.

Funkcje aktywacji warstw konwolucyjnych znacząco wpływają na proces uczenia. Brak funkcji, czy aktywacja tożsamościowa wykazywał znaczną niestabilność, szczególnie przy zbyt dużych wartościach parametru Learning Rate, jednak na początku procesu uczenia wykazywały się szybkim przyrostem dokładności. Podobnie jak aktywacja Leaky RELU, której właściwości matematyczne są bardzo podobne do tożsamościowej, obie szybko osiągały swoje ekstrema z których nie mogły się posunąć do przodu. Funkcje o nieujemnym zbiorze wartości jak RELU czy Sigmoida wykazały się dużo gorszymi osiągnięciami, co może sugerować potrzebę korekt map konwolucyjnych. Aktywacja TANH w większości przypadków okazywała się być najlepszą funkcją aktywacji, oferowała najlepsze wyniki uczenia. Posiada jednocześnie część ujemną, oraz jest ograniczona przez co znacznie trudniej jest jej wpaść w niestabilność w procesie uczenia.

Ekstrakcja do dwóch cech poprzez uczące się warstwy konwolucyjne dla zbioru MNIST pozwoliła na wytrenowanie modeli klasyfikujących z celnością bliską 90%. Jest to wynik bardzo dobry, znacznie przewyższający metody ekstrakcji zastosowane w pierwszej części projektu. Pokazuje to, że nawet czynność ekstrakcji cech może być wykonana przez model który wymaga jedynie parametryzacji i może dorównać i przewyższać metodom projektowanym przez człowieka. Przy zbiorach CIFAR10 zaprojektowanie takiej metody wydaje się bardzo trudnym zadaniem, kiedy model potrafi osiągnąć celność przewyższającą 50% na własnych cechach.

Na zbiorze CIFAR10 klasyfikacja okazała się zadaniem trudnym, nawet model nie forsujący redukcji informacji dla celów wizualizacyjnych klasyfikował w okolicach 90%. Po macierzy pomyłek i odnosząc się do etykiet zaobserwować można że model głównie myli między sobą zwierzęta. Zdjęcia są w bardzo słabej jakości i odróżnienie ich jest zadaniem trudnym dla człowieka, wyniki takie więc wydają się bardzo zadowalające.

Augmentacja danych treningowych pozwala nam na osiągnięcie ich większej ilości, poprzez niewielkie zmiany w obrazach źródłowych. Poprawnie i dobrze dobrana augmentacja pozwala na zwiększenie różnorodności w zbiorze treningowym, co może przyczynić się do poprawy dokładności wytrenowania modelu. Jednakże w przeprowadzonych eksperymentach zaobserwowano, że zaprojektowane augmentacje rotacji oraz zmiany kontrastu czy nasycenia obrazu nie wpływały znacząco na zmianę wartości accuracy. Szczególnie zbiór MNIST ze względu na niskie skomplikowanie osiągał świetne wyniki i augmentacja wydaje się nie mieć możliwości mu pomóc ze względu na osiągnięcie limitu informacji jakie model może interpretować. W przypadku zbioru CIFAR10, gdyby obrazy były w większej rozdzielczości, a nie 32x32 piksele, augmentacja poprzez np. random crop, aby przybliżyć znajdujący się na zdjęciu obiekt, być może pozwoliłaby na poprawę w rozpoznawaniu zwierząt między sobą.